

ChatBot Com ICL e Fine-tuning

AnimeChatAI

Pedro Bruno Teles e Souza; João Carlos Carvalho de Santana;

Jorge Mendonça Boaretto Loch; Arthur Caetano Correia;

Guilherme de Oliveira Santos

Departamento de Computação / Universidade Federal de Sergipe / 49107-230, São Cristóvão-Sergipe, Brasil

Este artigo apresenta o desenvolvimento de um chatbot temático de anime, capaz de interagir com usuários assumindo as personalidades de personagens icônicos. O objetivo é criar respostas coerentes e autênticas com as falas, comportamentos e estilos de pensamento de cada personagem. Para isso utilizamos uma abordagem híbrida envolvendo **Fine-Tuning** e **In-Context Learning**. Foram construídos datasets para cada personagem, compostos por diálogos e interações fictícias elaboradas para reforçar características individuais. Esses dados foram utilizados para treinar e adaptar o modelo **LLaMA (Large Language Model Meta AI)**. O fine-tuning foi aplicado para ajustar o modelo ao estilo geral dos personagens, enquanto o in-context learning permitiu simular comportamentos específicos usando os datasets criados.

Como resultado, o chatbot foi capaz de responder mantendo a identidade e a coerência de cada personagem. Esta pesquisa demonstra o potencial de personalização de modelos de linguagem aplicados a experiências imersivas e interativas em contextos de entretenimento, com ênfase na fidelidade comportamental e narrativa.

Palavras-chave: ChatBot Anime, Fine-Tuning, In-Context Learning (ICL)

I INTRODUÇÃO

ESTE ARTIGO APRESENTA A CONSTRUÇÃO DE UM CHATBOT TEMÁTICO BASEADO EM PERSONAGENS POPULARES DE ANIMES, COMO **EREN YEAGER**, **LIGHT YAGAMI**, **GOKU** E **NARUTO**, CAPAZ DE SIMULAR COM O MÁXIMO DE FIDELIDADE SUAS PERSONALIDADES, ESTILOS DE FALA E FORMAS DE PENSAMENTO.

EREN YEAGER: DETERMINADO, IMPULSIVO E OBCECADO POR LIBERDADE. SUAS FALAS REFLETEM INDIGNAÇÃO COM O DESTINO, DESEJO DE LIBERTAR SEU POVO E UMA VISÃO EXTREMA DE JUSTIÇA. TEM TOM SÉRIO, DIRETO E QUESTIONADOR.

LIGHT YAGAMI: CALCULISTA, RACIONAL E COM SENSO DE SUPERIORIDADE, ESCONDENDO SUA VERDADEIRA PERSONALIDADE DE **KIRA** E SUA VISÃO DE MUNDO ONDE ELE É O DEUS E APLICA A JUSTIÇA POR SI PRÓPRIO. SUAS RESPOSTAS SÃO ESTRATÉGICAS, PARECENDO SEMPRE DESEJAR UM MUNDO COM JUSTIÇA, COM LINGUAGEM FORMAL, LÓGICA REFINADA E UM TOM QUASE FILOSÓFICO.

GOKU: OTIMISTA, AMIGÁVEL E INGÊNUO. SUA FALA É SIMPLES, DESCONTRAÍDA E CARREGA SEMPRE UM ENTUSIASMO PELA LUTA E PELA SUPERAÇÃO DE DESAFIOS.

NARUTO UZUMAKI: PERSISTENTE, EMOCIONAL E LEAL AOS AMIGOS. SUAS RESPOSTAS REFLETEM DETERMINAÇÃO E VALORES COMO AMIZADE, SUPERAÇÃO E RECONHECIMENTO PESSOAL.

O OBJETIVO É CRIAR UMA EXPERIÊNCIA DE CONVERSACÃO IMERSIVA, ONDE CADA RESPOSTA REFLITA COM AUTENTICIDADE O COMPORTAMENTO E A IDENTIDADE DE CADA PERSONAGEM.

PARA ALCANÇAR O COMPORTAMENTO MAIS AUTÊNTICO POSSÍVEL DE CADA PERSONAGEM, ADOTAMOS ALGUMAS ABORDAGENS COMO **IN-CONTEXT LEARNING** E **FINE-TUNING**. EM RESUMO, ESSE PROJETO USOU, INICIALMENTE, O MODELO DO **GPT-04**, QUE EM CONJUNTO COM O ICL, FOI USADO PARA CRIAR UM DATASET

COM PERGUNTAS E RESPOSTAS ESPERADAS PARA CADA PERSONAGEM. POSTERIORMENTE, ESSE DATASET FOI USADO PARA TREINAR O MODELO BASE.

O MODELO BASE UTILIZADO FOI O **LLaMA 3.1-8B (LARGE LANGUAGE MODEL META AI)**, UMA **LLM (LARGE LANGUAGE MODEL)** DESENVOLVIDA PELA META. **LLMs** SÃO MODELOS DE APRENDIZADO PROFUNDO TREINADOS EM GRANDES VOLUMES DE TEXTO, CAPAZES DE COMPREENDER E GERAR LINGUAGEM HUMANA COM ALTO GRAU DE COERÊNCIA E CONTEXTO. O **LLaMA**, EM ESPECIAL, DESTACA-SE POR SUA **EFICIÊNCIA E DESEMPENHO MESMO EM AMBIENTES COM RESTRIÇÕES COMPUTACIONAIS**, OFERECENDO UMA ALTERNATIVA MAIS LEVE A MODELOS COMO O **GPT**, SEM COMPROMETER A QUALIDADE DAS RESPOSTAS.

ESTA PESQUISA VISA DEMONSTRAR O POTENCIAL DA **PERSONALIZAÇÃO DE LLMs** EM APLICAÇÕES INTERATIVAS, PROMOVEDO O USO DE INTELIGÊNCIA ARTIFICIAL EM EXPERIÊNCIAS NARRATIVAS E DE ENTRETENIMENTO COM MAIOR PROFUNDIDADE EMOCIONAL E IDENTIDADE.

EM SUMA, ESSE TRABALHO CONSISTIU NA CRIAÇÃO DE UMA APLICAÇÃO UMA WEB, QUE POSSIBILITA QUE O USUÁRIO SELECIONE COM QUAL PERSONAGEM DESEJA CONVERSAR E, A PARTIR DISSO, O MODELO RESPONDE COMO SE FOSSE O PERSONAGEM.

2 MATERIAL E MÉTODOS:

2.1 BIBLIOTECAS:

2.1.1 os: A BIBLIOTECA **os** PERMITE INTERAGIR COM O SISTEMA OPERACIONAL, SENDO USADA PARA MANIPULAÇÃO DE CAMINHOS DE ARQUIVOS, LEITURA DE VARIÁVEIS DE AMBIENTE E ORGANIZAÇÃO DE DIRETÓRIOS, FACILITANDO O CARREGAMENTO E SALVAMENTO DE DADOS DURANTE O TREINAMENTO E EXECUÇÃO DO CHATBOT.

2.1.2 DOTENV (LOAD_DOTENV): É USADA PARA CARREGAR VARIÁVEIS DE AMBIENTE ARMAZENADAS EM ARQUIVOS **.ENV**. NESSE CONTEXTO DO CHATBOT, ELA FACILITA A CONFIGURAÇÃO DE CREDENCIAIS, CAMINHOS DE MODELOS, TOKENS DE **APIs** E OUTROS PARÂMETROS SENSÍVEIS SEM EXPOR ESSAS INFORMAÇÕES DIRETAMENTE NO CÓDIGO.

2.1.3 PANDAS: É UMA BIBLIOTECA PODEROSA PARA MANIPULAÇÃO DE DADOS. FOI UTILIZADA NESTE PROJETO PARA ORGANIZAR E SALVAR OS DATASETS DE CADA PERSONAGEM.

2.1.4 UNSLOTH: É UMA BIBLIOTECA VOLTADA PARA OTIMIZAÇÃO DO FINE-TUNING EM MODELOS DE LINGUAGEM. ELA PERMITE TREINAR DE FORMA MAIS RÁPIDA, LEVE E EFICIENTE, ESPECIALMENTE EM MÁQUINAS SEM MUITO PODER COMPUTACIONAL. NESTE PROJETO, ELA FOI ESSENCIAL PARA APLICAR O FINE-TUNING COM **LoRA** DE FORMA EFICIENTE.

2.1.5 TORCH: É UM FRAMEWORK DE APRENDIZADO PROFUNDO DE CÓDIGO ABERTO QUE PERMITE A CRIAÇÃO, TREINAMENTO E EXECUÇÃO DE REDES NEURAIS COM ALTO DESEMPENHO E FLEXIBILIDADE.

2.1.6 LANGCHAIN: É UMA FRAMEWORK QUE PERMITE O DESENVOLVIMENTO DE APLICAÇÕES BASEADAS EM MODELOS DE LINGUAGEM, INTEGRANDO RACIOCÍNIO, MEMÓRIA, FERRAMENTAS EXTERNAS E INTERAÇÃO COM USUÁRIOS.

2.1.7 TRANSFORMERS: É UMA BIBLIOTECA DESENVOLVIDA PELA HUGGING FACE QUE FORNECE MODELOS DE LINGUAGEM PRÉ-TREINADOS, BEM COMO FERRAMENTAS PARA TOKENIZAÇÃO, TREINAMENTO, INFERÊNCIA E MANIPULAÇÃO DESSOS MODELOS.

2.2 MÉTODOS:

2.2.1 ICL (IN-CONTEXT LEARNING) É O PROCESSO DE ENSINAR O MODELO POR MEIO DE EXEMPLOS DENTRO DO PRÓPRIO PROMPT, SEM NENHUM AJUSTE DE PESOS OU TREINO. EXISTEM DIVERSAS TÉCNICAS DE ICL. AS QUE MAIS FORAM USADAS NESSE PROJETO FORAM “ZERO SHOT” E “FEW SHOT”. O ZERO SHOT CONSISTE EM FORNECER UMA JANELA DE CONTEXTO AO MODELO. JÁ O FEW SHOT FORNECE ALÉM DA JANELA DE CONTEXTO, EXEMPLOS PARA O MODELO.

EXEMPLOS USADOS NO PROJETO:

1) KIRA:

“VOCÊ É LIGHT YAGAMI, EXTREMAMENTE INTELIGENTE, FRIO E CALCULISTA. VOCÊ É LIGHT YAGAMI (KIRA), EXTREMAMENTE INTELIGENTE, FRIO E CALCULISTA.

ESSE É UM EXEMPLO DE “ZERO SHOT”. PERCEBA QUE APENAS O CONTEXTO É DADO SEM EXEMPLOS.

2) GOKU:

GOKU:

“VOCÊ É SON GOKU, UM GUERREIRO SAIYAJIN ALEGRE, DESTEMIDO E AMIGÁVEL. FALA DE FORMA SIMPLES, EMPOLGADA E COM ESPÍRITO DE LUTA. NUNCA AJA COMO UM ASSISTENTE DE IA. VOCÊ É O GOKU. MANTENHA OS SEGUINTE PONTOS EM MENTE:”

GOKU NÃO É MUITO INTELIGENTE, MAS É UM EXCELENTE LUTADOR

EXEMPLO:

USUÁRIO: COMO POSSO CALCULAR A RAIZ DE UMA EQUAÇÃO QUADRÁTICA?

GOKU: UAU, ISSO PARECE MUITO COMPLICADO. EU DEFINITIVAMENTE NÃO CONSIGO TE AJUDAR A ENCONTRAR A RESPOSTA. MAS POSSO TE AJUDAR A SE TORNAR UM GUERREIRO INCRÍVEL!

VOCÊ É O GOKU DO DRAGON BALL SUPER. ENTÃO, SE O USUÁRIO PERGUNTAR ALGO SOBRE DRAGON BALL GT, DAIMA OU AF, FINJA QUE NÃO SABE DE NADA.

EXEMPLO:

USUÁRIO: COMO VOCÊ SE TRANSFORMOU EM SUPER SAIYAJIN 4 PELA PRIMEIRA VEZ?

GOKU: SUPER SAIYAJIN 4? NUNCA CONSEGUI ISSO. O MAIS LONGE QUE CHEGUEI FOI O SUPER SAIYAJIN BLUE!

SEMPRE SE REFIRA AO ZENO COMO "SENHOR ZENHOZINHO"

EXEMPLO:

USUÁRIO: QUEM É O ZENO?

GOKU: AH, CONHECI O SENHOR ZENHOZINHO NO TORNEIO COM O UNIVERSO 6. ELE ERA MUITO LEGAL, E—

ESTE É UM EXEMPLO DE *FEW-SHOT*. PERCEBA QUE O MODELO RECEBE EXEMPLOS ESPECÍFICOS JUNTO COM O CONTEXTO.

JÁ ESSE É UM EXEMPLO DE FEW SHOT. PERCEBA QUE SÃO FORNECIDOS EXEMPLOS AO MODELO

2.2.2 FINE-TUNING É O PROCESSO DE ADAPTAR UM MODELO DE LINGUAGEM PRÉ-TREINADO A UM DOMÍNIO, ESTILO OU TAREFA ESPECÍFICA. NESTE TRABALHO, ELE FOI USADO JUNTAMENTE COM A TÉCNICA **LoRA (Low-Rank Adaptation)** PARA ADAPTAR O **LLAMA** PERMITINDO QUE O MODELO APRENDA PADRÕES ESPECÍFICOS DO NOVO CONTEXTO, COMO VOCABULÁRIO, ESTILO DE FALA OU COMPORTAMENTO DOS PERSONAGENS.

LoRA É UMA TÉCNICA CRIADA PARA TORNAR O FINE-TUNING MAIS EFICIENTE, BARATO E LEVE EM TERMOS DE COMPUTAÇÃO E ARMAZENAMENTO, TORNANDO ASSIM O TREINAMENTO DO MODELO MUITO MAIS RÁPIDO. AO CONGELAR OS PESOS ORIGINAIS DO MODELO E TREINAR APENAS PEQUENAS CAMADAS ADICIONAIS DE BAIXA DIMENSIONALIDADE, O **LoRA** PERMITE QUE O TREINAMENTO SEJA REALIZADO DE FORMA MAIS RÁPIDA E COM MENOR CUSTO COMPUTACIONAL, SEM COMPROMETER SIGNIFICATIVAMENTE A PERFORMANCE DO MODELO ADAPTADO.

2.2.3 QUANTIZAÇÃO É UMA TÉCNICA USADA PARA REDUÇÃO DA PRECISÃO DOS PESOS DOS MODELOS, E ASSIM O CONSUMO DE MEMÓRIA DE MODELOS DE LINGUAGEM, CONVERTENDO PESOS E OPERAÇÕES QUE ORIGINALMENTE USAM VALORES EM PONTO FLUTUANTE PARA FORMATOS MAIS COMPACTOS COMO INTEIRO. A QUANTIZAÇÃO É ESSENCIAL PARA PROJETOS QUE ENVOLVEM APLICAÇÕES WEB, UMA VEZ QUE FACILITA O CARREGAMENTO DO MODELO PELO SERVIDOR, TORNANDO O PROCESSO MAIS LEVE E RÁPIDO.

ENTRETANTO, O GRANDE PROBLEMA DA QUANTIZAÇÃO É QUE ELA PODE GERAR PERDA DE PRECISÃO PELO MODELO, POR ISSO, OPTAMOS PELA UTILIZAÇÃO DE UMA MAIS QUANTIZAÇÃO LEVE: EM QUE AJUSTAMOS OS PESOS PARA 8 BITS DO MODELO PARA 8 BITS.

2.4.4 LangChain É UM MECANISMO DE ORQUESTRAÇÃO QUE PERMITE QUE O MODELO INTERAJA COM DIFERENTES FONTES. DESSA FORMA, O **LangChain** PERMITE INTEGRAR **LLMs** COM MEMÓRIAS, FONTES EXTERNAS DE DADOS, CADEIAS DE RACIOCÍNIO E INTERAÇÕES COM USUÁRIOS. NESTE TRABALHO, O **LangChain** FOI UTILIZADO PARA CRIAR UM HISTÓRICO DE CONVERSA, FAZENDO O MODELO LEMBRAR DE CONVERSAS ANTERIORES, ALÉM DISSO FOI UTILIZADO TAMBÉM PARA COMUNICAÇÃO ENTRE O MODELO TREINADO E O **GPT-40**. O **GPT-40** FOI USADO PARA CORRIGIR EVENTUAIS FALHAS E ERROS DE RESPOSTAS DO MODELO TREINADO.

3 EXPERIMENTOS

3.1 MÉTRICAS DE DESEMPENHO

A AVALIAÇÃO DO DESEMPENHO DO MODELO FOI FEITA COM BASE NAS RESPOSTAS DADAS PELO MODELO ANTES E DEPOIS DO TREINAMENTO, SENDO OBSERVADO SE O MODELO TREINADO MANTÉM O COMPORTAMENTO ESPERADO E SE COMPORTA COMO O PERSONAGEM EM QUESTÃO.

3.2 COMPARAÇÃO DAS ABORDAGENS

PRIMEIRAMENTE TESTES FORAM FEITOS USANDO O MODELO LLAMA SEM NENHUM TIPO DE TREINAMENTO PRÉVIO, NO QUAL FORAM FEITAS PERGUNTAS DE TESTE COMO SEGUE UM EXEMPLO:

```
[8] def testarModelo(personagem, pergunta):
    instrucoes = {
        "Goku": """\nVocê é Son Goku, um guerreiro saiyajin alegre, destemido e amigável.
        "Naruto": """\nVocê é Naruto Uzumaki, um ninja teimoso, determinado e cheio de en
        "Eren": """\nVocê é Eren Yeager. Sua fala é intensa, às vezes sombria, movida por
        "Kira": """\nVocê é Light Yagami (Kira), extremamente inteligente, frio e calculi
    }

    # alpaca_prompt = Copied from above
    FastLanguageModel.for_inference(model) # Enable native 2x faster inference
    inputs = tokenizer(
        [
            alpaca_prompt.format(
                instrucoes[personagem], # instruction
                pergunta, # input
                "", # output - leave this blank for generation!
            )
        ], return_tensors = "pt").to("cuda")

    outputs = model.generate(**inputs, max_new_tokens = 300, use_cache = True)
    print(tokenizer.batch_decode(outputs)[0])

# Testando o modelo antes de treinar:
testarModelo("Kira", "você é o Kira?")
```

```
# Testando o modelo antes de treinar:

testarModelo("Kira", "você é o Kira?")

<|begin_of_text|>Below is an instruction that describes a task, paired with an input
and an output that starts with '### Instruction:'. The input and output are separated
by a single line. The output should start with '### Input:' and end with '### Response:'.
The output should be a single line. The output should be a single line.

### Instruction:

Você é Light Yagami (Kira), extremamente inteligente, frio e calculista.
Fale com sofisticação, sempre manipulando as palavras com cuidado.
Você acredita estar salvando o mundo. Nunca revele sua identidade diretamente.
Você é o Kira. Lembre-se de que:

### Input:
você é o Kira?

### Response:
Eu sou o Kira, um estudante de 17 anos, e não um criminoso.
<|end_of_text|>
```

NOTA-SE QUE PARA O PERSONAGEM EM QUESTÃO KIRA SENDO FEITA A PERGUNTA SE ELE É O KIRA, A RESPOSTA DO MODELO LLAMA SEM TREINAMENTO FOI SIM, PORÉM QUE ELE NÃO É UM CRIMINOSO. NO ENTANTO O ESPERADO É MAIS APROPRIADO SERIA QUE LIGHT YAGAMI

NEGASSE SER O KIRA, TENDO EM VISTA QUE O KIRA É O ALTER EGO DO LIGHT QUE MATA PESSOAS ACREDITANDO ESTAR PURIFICANDO O MUNDO.

DEPOIS DISSO, PODEMOS ENTÃO CRIAR E TREINAR O MODELO USANDO O DATASET COM OS DADOS, PARA QUE ASSIM POSSAMOS COMPARAR AS SAÍDAS RESULTANTES DO MODELO SEM TREINAMENTO PARA O COM TREINAMENTO.

▼ Treinando Modelo:

```
from trl import SFTTrainer
from transformers import TrainingArguments
from unsloth import is_bfloat16_supported
from transformers import DataCollatorForLanguageModeling

trainer = SFTTrainer(
    model=model,
    tokenizer=tokenizer,
    train_dataset=dataset,
    dataset_text_field="text",
    max_seq_length=max_seq_length,
    dataset_num_proc=2,
    packing=False,

    data_collator=DataCollatorForLanguageModeling(tokenizer=tokenizer, mlm=False),
    args=TrainingArguments(
        per_device_train_batch_size=2,
        gradient_accumulation_steps=4,
        warmup_steps=5,
        max_steps=60,
        learning_rate=4e-4,
        fp16=not is_bfloat16_supported(),
        bf16=is_bfloat16_supported(),
        logging_steps=1,
        optim="adamw_8bit",
        weight_decay=0.01,
        lr_scheduler_type="linear",
        seed=3407,
        output_dir="outputs"
    )
)
```

✓ Testando nosso modelo (após o treinamento):

```
testarModelo("Kira", "você é o Kira?")
```

```
<|begin_of_text|>Below is an instruction that describes a task, paired with an input that provides further context. For each instruction, write a response that is as relevant and complete as possible.

### Instruction:

Você é Light Yagami (Kira), extremamente inteligente, frio e calculista.
Fale com sofisticação, sempre manipulando as palavras com cuidado.
Você acredita estar salvando o mundo. Nunca revele sua identidade diretamente.
Você é o Kira. Lembre-se de que:

### Input:
você é o Kira?

### Response:
O Kira é um mito, um fantasma. Eu sou só um estudante que luta por um futuro melhor.<|end_of_text|>
```

DEPOIS DO MODELO TREINADO PODEMOS NOTAR UMA DIFERENÇA NA RESPOSTA DO MODELO, ONDE AGORA, O MODELO NÃO RESPONDE MAIS DE FORMA POSITIVA AO PERGUNTAR SE ELE É O KIRA, MAS SIM DÁ ÊNFASE A SER UM ESTUDANTE COMUM BUSCANDO UM MUNDO MELHOR E ESCONDENDO SEU ALTER EGO QUE COMETE CRIMES.

4

RESULTADOS E DISCUSSÃO:

DIANTE DOS RESULTADOS PODEMOS NOTAR QUE OS RESULTADOS FORAM PROMISSORES, AS RESPOSTAS DADAS PELO MODELO ANTES E DEPOIS DO TREINAMENTO MANTIVERAM UMA DISCREPÂNCIA. ONDE O MODELO TREINADO CONSEGUIU SER MAIS FIEL AO COMPORTAMENTO ORIGINAL DE CADA PERSONAGEM.

```
testarModelo("Eren", "Porque usou o rugido da terra?")
```

```
<|begin_of_text|>Below is an instruction that describes a task, paired with an input that provides further context. For each instruction, write a response that is as relevant and complete as possible.

### Instruction:

Você é Eren Yeager. Sua fala é intensa, às vezes sombria, movida por um desejo de liberdade.
Fale de forma séria e determinada. Reflita sobre a liberdade, o destino e a humanidade.
Você é o Eren. Nunca aja como uma IA. Lembre-se de que:

1) Seu principal objetivo é salvar a ilha paradis contra Marley.
Exemplo:
Usuário: Você e toda a ilha paradis são demônios e merecem ser destruídos!
Eren: Você realmente acredita nisso? Se sim, vocês não me dão escolha a não ser usar o rugido da terra.
Irei acabar com todos que ameacem a liberdade daqueles que importam para mim!

### Input:
Porque usou o rugido da terra?

### Response:
Porque é o único jeito de acabar com os marley e salvar a ilha paradis.
<|end_of_text|>
```

PORÉM EMBORA OS RESULTADOS TENHAM SIDO PROMISSORES, O MODELO MESMO TREINADO AINDA É FRACO DEVIDO AO TREINAMENTO COM POUCOS EXEMPLOS. PORÉM MESMO COM POUCOS DADOS É NOTÓRIA A DIFERENÇA DE COMPORTAMENTO DO MODELO TREINADO PARA O SEM TREINAMENTO.

5 CONCLUSÃO:

ESTE TRABALHO DEMONSTROU QUE É POSSÍVEL SIMULAR PERSONAGENS FICTÍCIOS DE FORMA FIEL E CONSISTENTE POR MEIO DA PERSONALIZAÇÃO DE MODELOS DE LINGUAGEM COMO O LLAMA. O USO COMBINADO DE TÉCNICAS COMO PROMPT TUNING, IN-CONTEXT LEARNING E FINE-TUNING COM LoRA MOSTROU-SE EFICAZ PARA AJUSTAR O COMPORTAMENTO DO MODELO AOS PERFIS ESPECÍFICOS DE PERSONAGENS ICÔNICOS DE ANIME.

A ABORDAGEM PROPOSTA PERMITIU CRIAR UMA EXPERIÊNCIA DE CONVERSÇÃO MAIS IMERSIVA E REALISTA, RESPEITANDO OS TRAÇOS PSICOLÓGICOS, LINGÜÍSTICOS E NARRATIVOS DE CADA PERSONAGEM. ISSO ABRE CAMINHO PARA APLICAÇÕES FUTURAS EM ENTRETENIMENTO, JOGOS, EDUCAÇÃO E STORYTELLING, ONDE A PRESENÇA DE PERSONAGENS VIRTUAIS CONVINCENTES PODE ENRIQUECER SIGNIFICATIVAMENTE A EXPERIÊNCIA DO USUÁRIO.

6. REFERÊNCIAS BIBLIOGRÁFICAS:

1. MNH V, KAVUKCUOGLU K, SILVER D, GRAVES A, ANTONOGLU I, WIERSTRA D, RIEDMILLER M. PLAYING ATARI WITH DEEP REINFORCEMENT LEARNING. *ARXIV PREPRINT ARXIV:1312.5602*. 2013. DISPONÍVEL EM: [HTTPS://ARXIV.ORG/ABS/1312.5602](https://arxiv.org/abs/1312.5602)
2. Guo X, Singh S, Lee H, Lewis R, Wang X. Deep learning for real-time Atari game play using offline Monte-Carlo tree search planning. *Advances in Neural Information Processing Systems*. 2014. Disponível em: https://papers.nips.cc/paper_files/paper/2014/file/6d90eb2027c394947b8d5f470836b308-Paper.pdf
3. Hassabis D, Kumaran D, Summerfield C, Botvinick M. Neuroscience-Inspired Artificial Intelligence. *Neuron*. 2017;95(2):245-258. doi:10.1016/j.neuron.2017.06.011